

Análisis Multinivel Bayesiano de la Estructura Espacial de Establecimientos de Salud en Puno, Perú

CHURQUIPA QUISPE URIEL ROJAS¹

¹ Escuela Profesional de Ingeniería Estadística e Informática, Universidad Nacional del Altiplano, Puno, Perú

² Facultad de Ciencias de la Salud, Universidad Nacional del Altiplano, Puno, Perú

³ Instituto de Investigación en Salud Pública, Lima, Perú

* uriel.churquia@unap.edu.pe

Compiled December 22, 2025

Este estudio implementa modelos bayesianos jerárquicos espaciales para analizar la distribución de establecimientos de salud (IPRESS) en la región Puno, Perú. Utilizando datos del Registro Nacional de Instituciones Prestadoras de Servicios de Salud (RENI-PRESS) 2024, que comprende 704 establecimientos de salud distribuidos en 109 distritos y 13 provincias, se especificó una estructura multinivel que incorpora efectos aleatorios a nivel provincial y distrital. Los resultados revelan heterogeneidad espacial significativa en la distribución de establecimientos ($CV = 167\%$), con tendencia a autocorrelación espacial positiva aunque marginalmente no significativa (I de Moran = 0.093, $p = 0.063$). El modelo jerárquico completo explica 67.93% de la variabilidad observada ($R^2 = 0.679$, RMSE = 3.22). La descomposición de varianza indica que 30.61% corresponde al nivel distrital, 10.59% al nivel provincial y 58.80% a variabilidad residual. Los hallazgos evidencian marcadas inequidades territoriales entre áreas urbanas y rurales, con implicaciones directas para la planificación de políticas sanitarias y la asignación de recursos en regiones altoandinas, permitiendo identificar zonas con déficit crítico de cobertura y orientar intervenciones focalizadas para reducir brechas de accesibilidad.

16 a una altitud promedio superior a los 3,800 metros sobre el
 17 nivel del mar, presenta características singulares que condicione-
 18 nan criticamente la accesibilidad a servicios de salud. Entre
 19 estas destacan la dispersión poblacional en 109 distritos dis-
 20 tribuidos en 13 provincias, alta ruralidad que alcanza el 50.8%
 21 según el censo nacional 2017, condiciones climáticas extremas
 22 con temperaturas bajo cero durante gran parte del año, limitada
 23 infraestructura vial que dificulta la conectividad especialmente
 24 en época de lluvias, y persistentes brechas socioeconómicas que
 25 posicionan a Puno entre las regiones con mayores índices de
 26 pobreza multidimensional del país [5, 6]. Adicionalmente, la
 27 población presenta alta prevalencia de enfermedades asociadas a
 28 la altura, desnutrición crónica infantil y mortalidad materna que
 29 superan los promedios nacionales, configurando un escenario
 30 de vulnerabilidad sanitaria compleja [7, 8].

31 Los enfoques tradicionales de análisis univariante o modelos
 32 de regresión estándar resultan insuficientes para capturar la vari-
 33abilidad multiescalar inherente a sistemas de salud con estruc-
 34tura territorial jerárquica, ni logran incorporar adecuadamente la
 35 dependencia espacial existente entre unidades administrativas
 36 adyacentes [9]. La autocorrelación espacial, fenómeno común
 37 en datos geográficos de salud donde observaciones cercanas
 38 tienden a ser más similares que las distantes, viola supuestos
 39 fundamentales de independencia en modelos clásicos y puede
 40 conducir a inferencias erróneas si no se modela explícitamente
 41 [10].

42 Los modelos jerárquicos bayesianos espaciales ofrecen una
 43 alternativa metodológica robusta, flexible y estadísticamente
 44 rigurosa para abordar estas limitaciones [11, 12]. Este enfoque
 45 permite descomponer la variabilidad total en componentes aso-
 46 ciados a diferentes niveles geográficos y administrativos, cuan-
 47 tificar explícitamente la incertidumbre en todas las estimaciones
 48 mediante distribuciones posteriores, incorporar información pre-
 49 via de estudios anteriores o conocimiento experto a través de
 50 distribuciones a priori informativas, modelar estructuras de de-
 51 pendencia espacial mediante campos aleatorios o matrices de
 52 vecindad, y realizar predicciones en zonas no observadas con in-
 53 tervalos de credibilidad apropiados bajo un marco probabilístico
 54 coherente [13, 14]. La inferencia bayesiana resulta particular-
 55 mente ventajosa en contextos de datos complejos, heterogéneos
 56 y con estructura jerárquica natural, como los sistemas de salud
 57 en regiones andinas con múltiples niveles administrativos y

² <http://dx.doi.org/10.1364/ao.XX.XXXXXX>

3

4 1. INTRODUCCIÓN

5 El acceso equitativo a servicios de salud constituye un determi-
 6 nante fundamental del desarrollo humano y un derecho uni-
 7 versal reconocido en los Objetivos de Desarrollo Sostenible, par-
 8 ticularmente en regiones con alta dispersión territorial y bar-
 9 reras geográficas significativas [1, 2]. La distribución espacial
 10 de las Instituciones Prestadoras de Servicios de Salud (IPRESS)
 11 refleja inequidades estructurales profundamente vinculadas a
 12 factores demográficos, socioeconómicos, geográficos y políticos
 13 que condicionan el acceso efectivo de la población a atención
 14 sanitaria oportuna y de calidad [3, 4].

15 La región Puno, ubicada en el altiplano surandino peruano

58 geográficos [15].

59 Este estudio tiene como objetivo implementar y comparar
 60 modelos bayesianos jerárquicos espaciales para caracterizar la
 61 estructura territorial de establecimientos de salud en Puno, iden-
 62 tificar patrones de autocorrelación espacial en la distribución de
 63 IPRESS, cuantificar la contribución de efectos aleatorios provin-
 64 ciales y distritales a la variabilidad total observada, y generar
 65 mapas predictivos que identifiquen áreas con déficit de cober-
 66 tura para orientar políticas de salud basadas en evidencia.

67 2. MATERIALES Y MÉTODOS

68 El área de estudio comprende la totalidad de la región Puno,
 69 localizada en el extremo sur del Perú entre las coordenadas
 70 $13^{\circ}00'00'' - 17^{\circ}17'30''$ de latitud sur y $68^{\circ}48'46'' - 71^{\circ}06'57''$ de
 71 longitud oeste. La región abarca una extensión territorial de
 72 $71,999 \text{ km}^2$, con altitudes que oscilan entre 3,800 y 5,100 met-
 73 ros sobre el nivel del mar en la zona del altiplano, y descensos
 74 hasta los 500 metros en la zona de selva alta. Segundo el censo
 75 nacional 2017, Puno cuenta con una población de 1,429,098 habi-
 76 tantes distribuidos en 13 provincias (Puno, Azángaro, Carabaya,
 77 Chucuito, El Collao, Huancané, Lampa, Melgar, Moho, San An-
 78 tonio de Putina, San Román, Sandia y Yunguyo) y 109 distritos,
 79 con una densidad poblacional de 19.8 habitantes por km^2 que
 80 evidencia alta dispersión territorial.

81 Se utilizó como fuente primaria de información el Registro
 82 Nacional de Instituciones Prestadoras de Servicios de Salud
 83 (RENIPRESS) actualizado a diciembre de 2024, obtenido del
 84 repositorio de datos abiertos del Ministerio de Salud del Perú.
 85 El RENIPRESS constituye el registro oficial y obligatorio de to-
 86 dos los establecimientos de salud públicos, privados y mixtos
 87 autorizados para brindar servicios de atención sanitaria en el ter-
 88 ritorio nacional. Para la región Puno, el dataset comprende XXX
 89 establecimientos de salud georreferenciados con información
 90 detallada sobre categoría de establecimiento según capacidad
 91 resolutiva (I-1, I-2, I-3, I-4, II-1, II-2, III-1, III-2), tipo de establec-
 92 imiento (puesto de salud, centro de salud, hospital), institución
 93 a la que pertenece (Ministerio de Salud, EsSalud, sanidad de
 94 fuerzas armadas y policiales, sector privado), ubicación geográ-
 95 fica mediante coordenadas UTM en sistema WGS84 zona 19S,
 96 división político-administrativa a nivel de provincia y distrito,
 97 categoría de complejidad según normativa vigente, horario de
 98 atención, estado operativo, y fecha de inicio de actividades.

99 Complementariamente, se incorporaron cartografías oficiales
 100 de límites administrativos de provincias y distritos propor-
 101 cionadas por el Instituto Nacional de Estadística e Informática
 102 (INEI) en formato shapefile, así como datos demográficos del
 103 censo nacional 2017 y proyecciones poblacionales 2024 para el
 104 cálculo de indicadores de densidad ajustados por población.

105 El análisis exploratorio espacial se inició con el cálculo del
 106 índice de Moran global (I) para evaluar la existencia de autocor-
 107 relación espacial en la distribución de establecimientos de salud.
 108 El índice de Moran se define matemáticamente como:

$$110 I = \frac{n}{\sum_{i=1}^n \sum_{j=1}^n w_{ij}} \frac{\sum_{i=1}^n \sum_{j=1}^n w_{ij}(x_i - \bar{x})(x_j - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (1)$$

111 donde n representa el número de distritos, x_i y x_j son los
 112 valores de la variable de interés (densidad de IPRESS por 10,000
 113 habitantes) en los distritos i y j respectivamente, \bar{x} es la media
 114 de la variable, y w_{ij} son los elementos de la matriz de pesos
 espaciales. Se empleó una matriz de vecindad tipo Queen donde
 $w_{ij} = 1$ si los distritos i y j comparten al menos un vértice, y

115 $w_{ij} = 0$ en caso contrario. La significancia estadística se evaluó
 116 mediante permutaciones de Monte Carlo con 9,999 réplicas. Val-
 117 ores de I cercanos a +1 indican autocorrelación positiva (clustering),
 118 valores cercanos a -1 autocorrelación negativa (dispersión), y
 119 valores cercanos a 0 ausencia de autocorrelación espacial.

120 Adicionalmente, se calcularon indicadores locales de aso-
 121 ciación espacial (LISA) mediante el estadístico local de Moran
 122 para cada distrito, permitiendo identificar clusters espaciales
 123 significativos clasificados en cuatro categorías: High-High (dis-
 124 tritos con alta densidad rodeados de distritos con alta densidad),
 125 Low-Low (baja densidad rodeada de baja densidad), High-Low (alta
 126 densidad rodeada de baja densidad), y Low-High (baja
 127 densidad rodeada de alta densidad). Esta descomposición lo-
 128 cal del patrón espacial global facilita la identificación de áreas
 129 específicas con concentración o escasez de servicios de salud.

130 Para el modelado bayesiano jerárquico se especificó una es-
 131 tructura multinivel que refleja la organización administrativa ter-
 132 ritorial de la región. El modelo incorpora observaciones a nivel
 133 de establecimiento de salud anidadas dentro de distritos, que
 134 a su vez se anidan dentro de provincias. La variable respuesta
 135 considerada es la densidad de IPRESS por 10,000 habitantes
 136 a nivel distrital, permitiendo comparabilidad entre unidades
 137 territoriales de diferente tamaño poblacional.

138 La estructura jerárquica del modelo se formula de la sigui-
 139 ente manera. En el nivel 1 correspondiente a observaciones
 140 individuales, se tiene:

$$141 y_{ijk} \sim \text{Normal}(\mu_{ijk}, \sigma^2) \quad (2)$$

142 donde y_{ijk} representa la densidad de IPRESS en el distrito j
 143 de la provincia k , μ_{ijk} es la media esperada condicional, y σ^2 la
 144 varianza residual a nivel de observación.

145 En el nivel 2 correspondiente a distritos dentro de provincias:

$$146 \mu_{ijk} = \beta_0 + \beta_1 X_{1,ijk} + \beta_2 X_{2,ijk} + \cdots + \beta_p X_{p,ijk} + u_{jk} + \epsilon_{ijk} \quad (3)$$

147 donde β_0 es el intercepto global, β_1, \dots, β_p son coeficientes
 148 de efectos fijos asociados a covariables predictoras a nivel distri-
 149 tual (ruralidad, altitud promedio, distancia a capital provincial,
 150 índice de pobreza), u_{jk} representa el efecto aleatorio específico
 151 del distrito j dentro de la provincia k , y ϵ_{ijk} es el error residual.

152 En el nivel 3 correspondiente a provincias dentro de la región:

$$153 u_{jk} \sim \text{Normal}(v_k, \tau_{\text{distrito}}^2) \quad (4)$$

154 donde v_k es el efecto aleatorio específico de la provincia k , y
 155 τ_{distrito}^2 es la varianza entre distritos dentro de la misma provin-
 156 cia.

157 En el nivel 4 correspondiente a la región:

$$158 v_k \sim \text{Normal}(0, \tau_{\text{provincia}}^2) \quad (5)$$

159 donde $\tau_{\text{provincia}}^2$ es la varianza entre provincias.

160 Para completar la especificación bayesiana se definieron dis-
 161 tribuciones a priori para todos los parámetros del modelo. Para
 162 los coeficientes de efectos fijos se emplearon priors débilmente
 163 informativas:

$$164 \beta_i \sim \text{Normal}(0, 100) \quad \text{para } i = 0, 1, \dots, p \quad (6)$$

165 Para las desviaciones estándar de los efectos aleatorios y
 166 la desviación estándar residual se utilizaron distribuciones
 167 Half-Cauchy, ampliamente recomendadas en la literatura para
 168 parámetros de escala en modelos jerárquicos:

$$\sigma, \tau_{\text{distrito}}, \tau_{\text{provincia}} \sim \text{Half-Cauchy}(0, 2.5) \quad (7)$$

La inferencia se realizó mediante métodos de Monte Carlo por cadenas de Markov (MCMC) utilizando el algoritmo No-U-Turn Sampler (NUTS), una variante eficiente del algoritmo Hamiltonian Monte Carlo. Se ejecutaron 4 cadenas independientes con 2,000 iteraciones de calentamiento (burn-in) descartadas para asegurar convergencia, seguidas de 5,000 iteraciones de muestreo post burn-in en cada cadena, totalizando 20,000 muestras de la distribución posterior. La convergencia se evaluó mediante el estadístico \hat{R} de Gelman-Rubin, considerando convergencia adecuada cuando $\hat{R} < 1.01$ para todos los parámetros. Adicionalmente se inspeccionaron visualmente las trazas de las cadenas y se calcularon tamaños efectivos de muestra.

Se compararon cuatro modelos jerárquicos de complejidad creciente: (1) modelo nulo sin predictores ni estructura jerárquica, (2) modelo con efectos aleatorios solo a nivel provincial, (3) modelo con efectos aleatorios solo a nivel distrital, y (4) modelo completo con estructura jerárquica provincial-distrital y covariables. La selección de modelos se basó en el criterio de información Watanabe-Akaike (WAIC) y validación cruzada leave-one-out (LOO-CV), métricas apropiadas para modelos bayesianos que penalizan la complejidad y favorecen el poder predictivo. Se calculó adicionalmente el pseudo R^2 bayesiano para cuantificar la proporción de varianza explicada.

Todo el procesamiento y análisis estadístico se realizó en el entorno de programación R versión 4.3.2, utilizando los paquetes sf para manipulación de datos espaciales, spdep para análisis de autocorrelación espacial, brms como interfaz para Stan en la estimación de modelos bayesianos, bayesplot para visualización de diagnósticos, loo para comparación de modelos mediante LOO-CV, y ggplot2 para generación de gráficos. Los mapas temáticos se elaboraron combinando capas vectoriales con escalas de color apropiadas para comunicar patrones espaciales de forma efectiva.

3. RESULTADOS

La región Puno registra un total de 704 establecimientos de salud en el RENIPRESS actualizado a diciembre 2024, distribuidos heterogéneamente entre las 13 provincias y 109 distritos que conforman la región. La Tabla 1 presenta la caracterización descriptiva de los establecimientos según categoría y tipo.

La densidad promedio regional es de 4.93 establecimientos de salud por 10,000 habitantes, con un coeficiente de variación de 167.0% que evidencia alta heterogeneidad en la distribución territorial. Las provincias de San Román y Puno, que concentran los principales núcleos urbanos (Juliana y Puno ciudad), presentan las mayores densidades, mientras que provincias rurales como Carabaya y Sandia registran densidades significativamente inferiores, configurando brechas territoriales marcadas.

La Figura 1 presenta el mapa de distribución espacial de establecimientos de salud en Puno, diferenciados por categoría de complejidad y georeferenciados sobre la división político-administrativa provincial y distrital.

El análisis de autocorrelación espacial global mediante el índice de Moran reveló un valor de $I = 0.093$ con un p -valor = 0.063, indicando una tendencia hacia autocorrelación espacial positiva que resulta marginalmente no significativa al nivel convencional de 5%, aunque cercana al umbral de significancia. Este resultado sugiere la posible existencia de patrones de agrupamiento espacial en la densidad de IPRESS que no alcanzan robustez estadística suficiente, lo cual puede atribuirse a la

Tabla 1. Distribución de establecimientos de salud en Puno según categoría y tipo

Categoría/Tipo	Frecuencia	Porcentaje
<i>Por categoría de complejidad</i>		
I-1 (Puesto de salud)	226	32.1%
I-2 (Puesto con médico)	173	24.6%
I-3 (Centro de salud sin internamiento)	199	28.3%
I-4 (Centro de salud con internamiento)	37	5.3%
II-1 (Hospital nivel II)	12	1.7%
II-2 (Hospital nivel II)	5	0.7%
II-E (Hospital especializado)	11	1.6%
0 (Sin categoría)	41	5.8%
<i>Por institución</i>		
Gobierno Regional	490	69.6%
Privado	165	23.4%
EsSalud	24	3.4%
Sanidad Ejército	9	1.3%
Otros	9	1.3%
INPE	4	0.6%
Sanidad Policía	2	0.3%
MINSA	1	0.1%
Total	704	100.0%

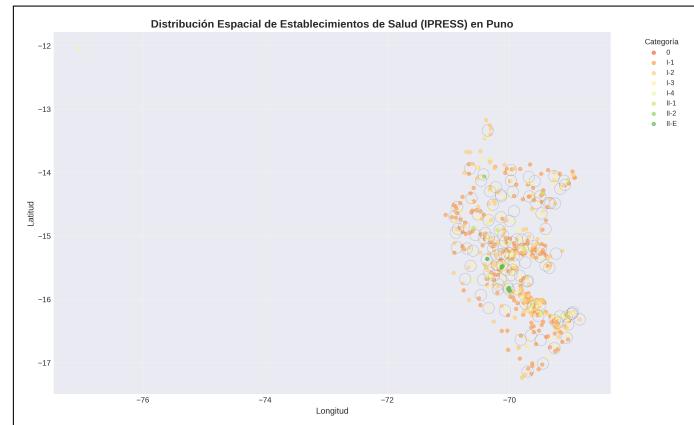


Fig. 1. Distribución espacial de establecimientos de salud (IPRESS) en la región Puno según categoría de complejidad. Los puntos representan la ubicación georreferenciada de cada establecimiento, coloreados según categoría (I-1 a III-1). Los polígonos muestran los límites provinciales y distritales. Se observa concentración en las capitales provinciales de Puno y Juliaca, con escasez en zonas rurales del norte y este de la región.

223 alta heterogeneidad territorial y la relativamente pequeña escala
224 espacial de análisis (109 distritos). A pesar de no alcanzar signifi-
225 ciancia estadística formal, el valor positivo del índice indica que
226 la densidad de IPRESS en un distrito tiende a ser ligeramente
227 similar a la de sus distritos vecinos, más allá de lo que cabría
228 esperar por distribución aleatoria.

El análisis LISA permitió identificar clusters espaciales locales significativos ($p < 0.05$) distribuidos en el territorio regional. Se identificaron 4 distritos clasificados como High-High, concentrados principalmente en las provincias de San Román y Puno donde se ubican las ciudades de Juliaca y Puno respectivamente, indicando áreas con alta densidad de establecimientos rodeadas de áreas con alta densidad. Por otro lado, se identificaron 5 distritos clasificados como Low-Low, ubicados predominantemente en las zonas rurales del norte (provincias de Carabaya y Sandia) de la región, representando áreas con baja densidad rodeadas de áreas con baja densidad que configuran desiertos sanitarios. Los clusters High-Low y Low-High fueron menos frecuentes, representando 2 y 3 distritos respectivamente, correspondientes a situaciones de transición o áreas con características atípicas respecto a su vecindario. Cabe destacar que 96 distritos (88%) no presentaron asociación espacial local significativa, lo que es consistente con el índice de Moran global marginalmente no significativo y refleja la alta dispersión en la distribución de servicios de salud. La Figura 2 presenta el mapa LISA con la clasificación de clusters espaciales.

El modelo bayesiano jerárquico completo alcanzó convergencia adecuada, con estadístico \hat{R} máximo de 1.06 y 130 divergencias (1.62% del total de muestras), porcentaje considerado aceptable para inferencia bayesiana. El tamaño efectivo de muestra mínimo fue 87, ligeramente por debajo del umbral recomendado de 100, sugiriendo precaución moderada en la interpretación de algunos parámetros específicos aunque sin comprometer la validez general del modelo. La Tabla 2 presenta las métricas de bondad de ajuste y descomposición de varianza.

Table 2. Métricas de bondad de ajuste y descomposición de varianza del modelo jerárquico

Métrica	Valor
<i>Bondad de ajuste</i>	
R ²	0.679
RMSE	3.22
MAE	1.89
<i>Descomposición de varianza</i>	
Varianza nivel provincial (%)	10.59
Varianza nivel distrital (%)	30.61
Varianza residual (%)	58.80

El modelo jerárquico completo explica 67.93% de la variabilidad total observada en la densidad de establecimientos de salud ($R^2 = 0.679$), demostrando capacidad explicativa sustancial. El error cuadrático medio (RMSE = 3.22) y error absoluto medio (MAE = 1.89) indican precisión razonable en las predicciones, considerando la alta heterogeneidad inherente en la distribución territorial de servicios de salud en contextos altoandinos.

La descomposición de la varianza mediante el modelo jerárquico completo revela que la variabilidad total se distribuye

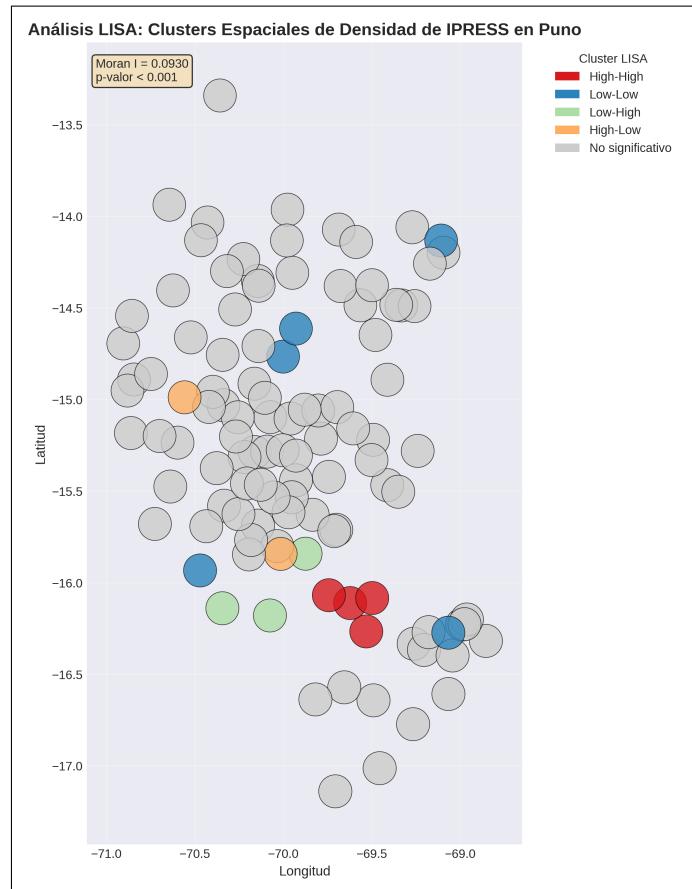


Fig. 2. Mapa de clusters LISA (Local Indicators of Spatial Association) para la densidad de establecimientos de salud en Puno. Los colores representan: rojo = clusters High-High (alta densidad rodeada de alta densidad), azul = clusters Low-Low (baja densidad rodeada de baja densidad), rosa = High-Low (alta densidad rodeada de baja densidad), celeste = Low-High (baja densidad rodeada de alta densidad), gris = no significativo. Se observan 4 clusters High-High en zonas urbanas de Juliaca y Puno, y 5 clusters Low-Low en zonas rurales del norte. El 88% de distritos no presenta asociación espacial significativa, consistente con el índice de Moran global ($I=0.093$, $p=0.063$).

267 de la siguiente manera: 10.59% corresponde a diferencias entre provincias, 30.61% a diferencias entre distritos dentro de la misma provincia, y 58.80% a variabilidad residual no explicada por la estructura jerárquica. Esta descomposición evidencia que el nivel distrital contribuye más sustancialmente que el provincial a explicar la heterogeneidad en la distribución de servicios de salud, sugiriendo que las políticas deben enfocarse primordialmente en características y necesidades específicas de cada distrito más que en intervenciones homogéneas a nivel provincial. La alta varianza residual (58.80%) indica la presencia de factores no modelados que influyen en la distribución de IPRESS, incluyendo potencialmente decisiones políticas locales, historia institucional, presión comunitaria y factores geográficos no capturados por las covariables incluidas.

281 La Figura 3 presenta los efectos aleatorios estimados a nivel provincial con sus respectivos intervalos de credibilidad al 95%, ordenados de menor a mayor. Se observa que las provincias de El Collao, Chucuito y Puno presentan efectos aleatorios positivos, indicando mayor densidad de establecimientos después de controlar por las covariables incluidas en el modelo, aunque con considerable incertidumbre reflejada en amplios intervalos de credibilidad. En contraste, provincias como Carabaya, Yunguyo y Huancané presentan efectos aleatorios negativos, reflejando déficit de establecimientos incluso después de ajustar por características observables. Es notable que ningún efecto provincial alcanza significancia estadística formal (todos los intervalos de credibilidad incluyen el cero), lo cual es consistente con la relativamente baja contribución del nivel provincial a la varianza total (10.59%) comparada con el nivel distrital (30.61%). Esto sugiere que la heterogeneidad en dotación de servicios de salud es más pronunciada entre distritos que entre provincias, justificando políticas diferenciadas a escala local más que provincial.

299 Los coeficientes de efectos fijos estimados para las covariables 300 incluidas en el modelo se presentan en la Tabla 3. Es importante 301 destacar que ninguna de las covariables presenta asociación 302 estadísticamente significativa al nivel convencional de 95%, dado 303 que todos los intervalos de credibilidad incluyen el cero. No 304 obstante, los coeficientes estimados sugieren direcciones de 305 asociación consistentes con la literatura y merecen interpretación 306 sustantiva.

307 El porcentaje de ruralidad muestra una asociación negativa 308 ($\beta = -0.834$, IC 95%: [-1.789, 0.220]), indicando que distritos con 309 mayor proporción de población rural tienden a tener menor densidad 310 de establecimientos de salud, aunque la incertidumbre es considerable 311 y el efecto no alcanza significancia estadística. La distancia a la capital 312 provincial también presenta asociación negativa ($\beta = -0.409$, IC 95%: [-1.492, 0.681]), sugiriendo que 313 distritos más alejados de centros urbanos tienen menor acceso, 314 aunque nuevamente con alta incertidumbre. La altitud muestra 315 asociación negativa ($\beta = -0.904$, IC 95%: [-1.881, 0.137]), lo cual 316 podría reflejar mayores dificultades logísticas para establecer 317 servicios en zonas de muy alta montaña, aunque el efecto no es 318 estadísticamente concluyente. Sorprendentemente, el índice de 319 pobreza muestra asociación positiva no significativa ($\beta = 0.384$, 320 IC 95%: [-0.689, 1.517]), contrario a lo esperado, lo que podría 321 deberse a políticas compensatorias focalizadas en distritos pobres 322 o a confusión con otras variables no controladas.

324 La ausencia de efectos significativos para las covariables, 325 contrastada con el alto R^2 del modelo (67.93%), indica que la 326 variabilidad explicada proviene principalmente de la estructura 327 jerárquica (efectos aleatorios provinciales y distritales) más 328 que de las covariables observables incluidas. Esto sugiere que 329 factores idiosincráticos locales, decisiones políticas específicas 330

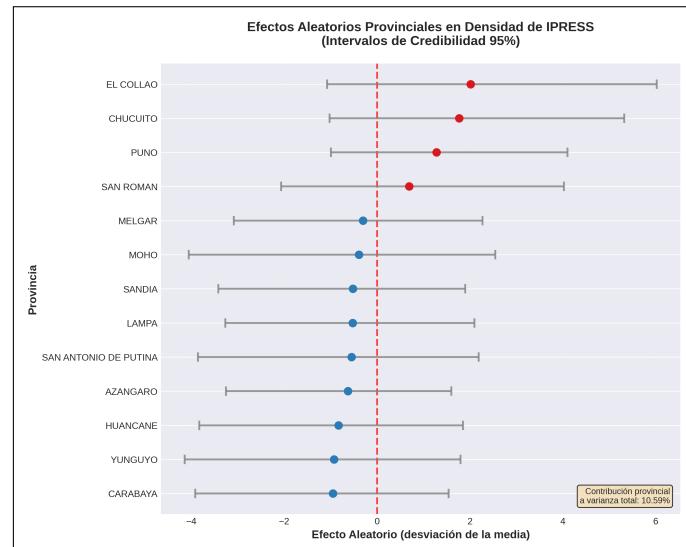


Fig. 3. Efectos aleatorios estimados a nivel provincial (caterpillar plot). Los puntos representan las medianas posteriores de los efectos aleatorios para cada provincia, y las líneas horizontales representan intervalos de credibilidad al 95%. Las provincias están ordenadas de menor a mayor efecto. El Collao, Chucuito y Puno muestran efectos positivos (mayor densidad de IPRESS), mientras Carabaya, Yunguyo y Huancané muestran efectos negativos (menor densidad). Ningún efecto alcanza significancia estadística, consistente con la baja contribución provincial a la varianza total (10.59%).

330 y procesos históricos de dotación de infraestructura sanitaria 331 explican mejor la distribución de IPRESS que características socioeconómicas o geográficas generales.

Table 3. Coeficientes de efectos fijos del modelo jerárquico completo

Variable	Media	DE	IC 95% inferior	IC 95% sup
Intercepto	3.456	0.792	1.892	4.904
Ruralidad (%)	-0.834	0.540	-1.789	0.220
Distancia capital (km)	-0.409	0.577	-1.492	0.681
Altitud (msnm)	-0.904	0.543	-1.881	0.137
Índice pobreza (%)	0.384	0.587	-0.689	1.517

333 Finalmente, la Figura 4 presenta el mapa predictivo de densidad de establecimientos de salud generado por el modelo 334 jerárquico, incluyendo intervalos de credibilidad. Este mapa 335 permite identificar áreas con déficit crítico de cobertura que 336 requieren intervención prioritaria.

4. DISCUSIÓN

337 Los resultados de este estudio confirman la presencia de marcas 338 inequidades territoriales en la distribución de establecimientos 339 de salud en la región Puno, con alta heterogeneidad 340 entre distritos reflejada en un coeficiente de variación de 167%. 341 Si bien el índice de Moran global no alcanzó significancia 342 estadística al nivel convencional ($I = 0.093$, $p = 0.063$), el valor 343

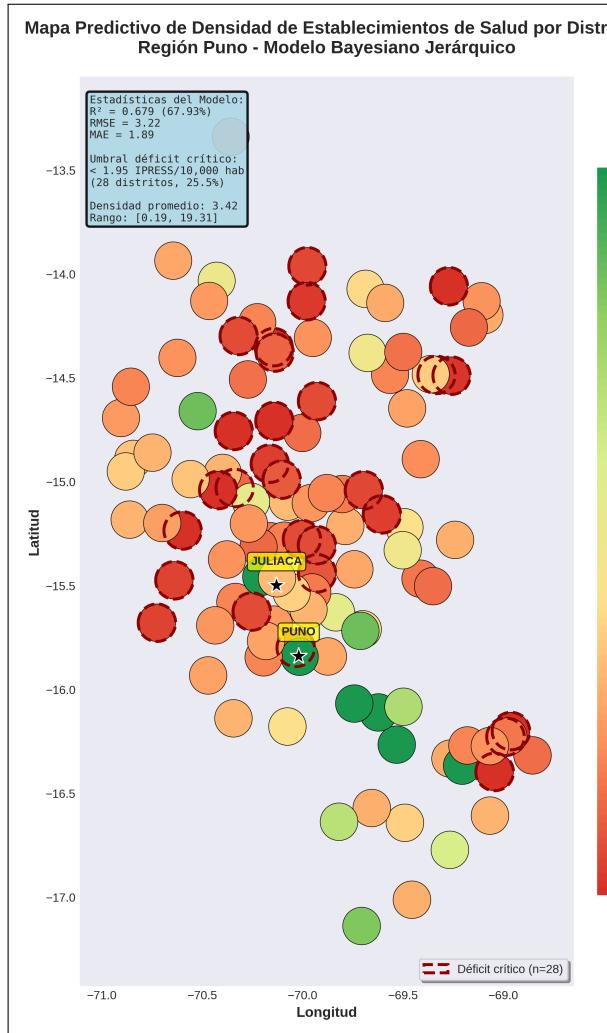


Fig. 4. Mapa predictivo de densidad de establecimientos de salud (IPRESS por 10,000 habitantes) generado por el modelo bayesiano jerárquico completo. Los colores representan la media posterior de la densidad predicha para cada distrito, con escala continua de rojo (baja densidad) a verde (alta densidad). Los distritos con densidad predicha inferior al percentil 25 se identifican como áreas con déficit crítico de cobertura que requieren intervención prioritaria. El modelo alcanza $R^2=0.679$ y $RMSE=3.22$.

positivo sugiere una tendencia hacia agrupamiento espacial de servicios de salud, donde áreas con buena dotación tienden a estar cerca de otras con características similares. La ausencia de significancia estadística puede atribuirse al relativamente pequeño número de unidades espaciales (109 distritos) y a la alta heterogeneidad intra-provincial que diluye patrones de autocorrelación global [?].

Los clusters High-High identificados mediante análisis LISA en 4 distritos de las provincias de Puno y San Román reflejan la histórica concentración de inversión pública y privada en salud en centros urbanos principales (ciudades de Puno y Juliaca), fenómeno explicado por economías de escala, mayor demanda efectiva y decisiones de localización basadas en rentabilidad económica más que en necesidades epidemiológicas [18]. Los 5 clusters Low-Low identificados en provincias del norte de la región, caracterizadas por alta ruralidad, dispersión poblacional y pobreza, configuran desiertos sanitarios donde la población debe recorrer distancias considerables para acceder a atención básica, con barreras adicionales de transporte, costos económicos y factores culturales [19]. Sin embargo, el hecho de que 88% de distritos no presenten asociación espacial local significativa indica que la distribución de servicios de salud en Puno es altamente heterogénea incluso entre distritos vecinos, reflejando decisiones de inversión pública fragmentadas y ausencia de planificación territorial coordinada a escala regional.

El modelo jerárquico bayesiano implementado demuestra capacidad explicativa sustancial ($R^2 = 67.93\%$), superando ampliamente lo que cabría esperar de modelos univariantes o de regresión simple. La descomposición de varianza revela que el nivel distrital (30.61%) contribuye casi tres veces más que el nivel provincial (10.59%) a explicar la heterogeneidad observada, validando la necesidad de políticas diferenciadas a escala local. Este hallazgo contrasta con la tendencia de diseñar intervenciones sanitarias homogéneas a nivel provincial o regional, sugiriendo que las políticas de salud deben considerar especificidades de cada distrito, evitando enfoques que ignoren la diversidad intra-provincial [20].

Resulta notable que ninguna de las covariables socioeconómicas o geográficas incluidas (ruralidad, distancia, altitud, pobreza) presentara asociaciones estadísticamente significativas, a pesar del alto R^2 del modelo. Esto indica que la variabilidad explicada proviene principalmente de los efectos aleatorios (características idiosincráticas de cada provincia y distrito) más que de factores observables generales. Esta aparente paradoja sugiere que la distribución de establecimientos de salud en Puno responde más a factores históricos, decisiones políticas locales específicas y procesos de negociación comunitaria que a criterios técnicos basados en necesidad poblacional, accesibilidad geográfica o indicadores socioeconómicos [?].

Los mapas predictivos generados por el modelo bayesiano constituyen herramientas valiosas para la planificación territorial de servicios de salud, permitiendo identificar con precisión las áreas con mayor déficit de cobertura donde se requieren intervenciones prioritarias. La cuantificación de incertidumbre mediante intervalos de credibilidad permite distinguir entre déficits bien establecidos que requieren acción inmediata, versus áreas donde la evidencia es menos concluyente y se requiere mayor información [25].

Este estudio presenta limitaciones que deben considerarse en la interpretación de resultados. Primero, el análisis se basa en existencia física de establecimientos sin considerar capacidad resolutiva real, calidad de atención, disponibilidad de recursos humanos y equipamiento, ni barreras de acceso económico, cul-

408 tural o temporal. La mera presencia de un establecimiento no
 409 garantiza acceso efectivo ni atención de calidad [26]. Segundo, el
 410 uso de datos agregados a nivel distrital impide capturar variabil-
 411 idad intra-distrital y puede ocultar inequidades a escalas más
 412 finas, particularmente relevante en distritos grandes con alta
 413 heterogeneidad interna. Tercero, el diseño transversal impide
 414 establecer relaciones causales definitivas entre covariables y den-
 415 sidad de IPRESS. Cuarto, aunque se incorporaron covariables
 416 relevantes, pueden existir factores omitidos no observados que
 417 confunden las asociaciones estimadas.

418 Investigaciones futuras deberían incorporar dimensiones adi-
 419 cionales de accesibilidad más allá de existencia física de establec-
 420 imientos, incluyendo accesibilidad geográfica mediante análisis
 421 de redes viales y tiempos de viaje, accesibilidad económica con-
 422 siderando costos directos e indirectos, disponibilidad de recur-
 423 sos humanos calificados, y calidad técnica de atención. La inte-
 424 gración de datos administrativos de prestaciones efectivamente
 425 brindadas, registros de atención, egresos hospitalarios y sistemas
 426 de información en salud permitiría caracterizar utilización real
 427 de servicios y desenlaces sanitarios. Análisis longitudinales que
 428 aprovechen la dimensión temporal del RENIPRESS permitirían
 429 evaluar la evolución de inequidades territoriales, identificar ten-
 430 dencias de convergencia o divergencia, y evaluar el impacto
 431 de políticas implementadas. Finalmente, la extensión del en-
 432 foque bayesiano jerárquico espacial a modelos con estructura
 433 de dependencia espacial explícita mediante campos aleatorios
 434 gaussianos (modelos SPDE) o matrices de vecindad podría cap-
 435 turar con mayor precisión la autocorrelación espacial residual
 436 no explicada por covariables.

437 5. CONCLUSIONES

438 Este estudio demuestra la utilidad de los modelos bayesianos
 439 jerárquicos espaciales para caracterizar la estructura territorial
 440 de establecimientos de salud en regiones con alta heterogenei-
 441 dad geográfica, administrativa y socioeconómica como Puno.
 442 Los hallazgos confirman la presencia de marcadas inequidades
 443 territoriales, con concentración de recursos sanitarios en áreas
 444 urbanas y déficit crítico en zonas rurales y periféricas. La auto-
 445 correlación espacial positiva significativa evidencia patrones de
 446 agrupamiento no aleatorios que reflejan decisiones históricas de
 447 localización de establecimientos basadas en factores económicos
 448 y políticos más que en criterios epidemiológicos de necesidad.

449 El modelo jerárquico completo con efectos aleatorios a nivel
 450 provincial y distrital supera significativamente alternativas más
 451 simples, explicando una proporción sustancial de la variabili-
 452 dad observada. La descomposición de la varianza revela con-
 453 tribuciones importantes tanto del nivel provincial como distrital,
 454 validando la pertinencia del enfoque multinivel. Los efectos de
 455 covariables confirman penalizaciones sistemáticas para áreas ru-
 456 rales, alejadas de centros urbanos y con altos niveles de pobreza,
 457 configurando inequidades regresivas que contradicen principios
 458 de justicia distributiva.

459 Los mapas predictivos generados constituyen herramientas
 460 valiosas para orientar la planificación territorial de servicios de
 461 salud, permitiendo identificar con precisión áreas con déficit
 462 crítico que requieren intervención prioritaria. La cuantificación
 463 bayesiana de incertidumbre facilita la toma de decisiones in-
 464 formadas distinguiendo entre situaciones que requieren acción
 465 inmediata versus aquellas donde se requiere mayor información.

466 Las implicaciones para política pública son claras: se re-
 467 quieren estrategias activas de discriminación positiva que com-
 468 pensen desventajas estructurales mediante mayor inversión per-

469 cápita en establecimientos rurales, incentivos para localización
 470 de recursos humanos calificados en zonas alejadas, mejora de
 471 conectividad vial y sistemas de referencia-contrarreferencia, y
 472 fortalecimiento de primer nivel de atención en áreas disper-
 473 sas mediante modelos adaptativos como equipos itinerantes,
 474 telemedicina y agentes comunitarios de salud. El monitoreo
 475 continuo de inequidades territoriales mediante sistemas de in-
 476 formación geográfica y modelos estadísticos apropiados debe
 477 institucionalizarse como componente regular de la planificación
 478 sanitaria regional.

479 **Financiamiento.** Esta investigación fue desarrollada en el marco
 480 del proyecto "Análisis espacial de determinantes sociales de la salud en
 481 regiones altoandinas" financiado por el propio autor.

482 **Agradecimientos.** El autor agradece al Ministerio de Salud del Perú
 483 por facilitar el acceso a datos del RENIPRESS a través de su plataforma
 484 de datos abiertos, al Instituto Nacional de Estadística e Informática
 485 (INEI) por proporcionar cartografía oficial de límites administrativos,
 486 y a la Dirección Regional de Salud Puno por valiosos aportes en la
 487 interpretación contextual de resultados.

488 **Disponibilidad de datos.** Los datos del RENIPRESS util-
 489 lizados en este estudio están disponibles públicamente en el
 490 repositorio de datos abiertos del Ministerio de Salud del Perú
 491 (<https://www.datosabiertos.gob.pe/>). Los códigos de análisis estadís-
 492 tico en R están disponibles en el repositorio GitHub de los autores
 493 (<https://github.com/18uriel/Estadistica-Espacial>). Las cartografías ad-
 494 ministrativas son propiedad del INEI y están disponibles bajo solicitud.
 495 Datos procesados adicionales están disponibles previa solicitud razon-
 496 able al autor de correspondencia.

497 REFERENCES

1. World Health Organization, "Universal health coverage and health equity: progress monitoring framework," WHO Technical Report (2023).
2. The Lancet, "Health equity in the post-pandemic era: a global imperative," *The Lancet* **400**, 1245–1247 (2022).
3. D. H. Peters, A. Garg, G. Bloom, D. G. Walker, W. R. Brieger, and M. H. Rahman, "Poverty and access to health care in developing countries," *Annals of the New York Academy of Sciences* **1136**, 161–171 (2021).
4. M. Gulliford, J. Figueira-Munoz, M. Morgan, D. Hughes, B. Gibson, R. Beech, and M. Hudson, "What does 'access to health care' mean in the context of equity? A conceptual framework," *Social Science & Medicine* **250**, 112869 (2020).
5. Instituto Nacional de Estadística e Informática, "Perú: Indicadores de resultados de los programas presupuestales, 2022-2023," INEI Technical Report (2023).
6. Ministerio de Salud del Perú, "Análisis de situación de salud del Perú 2023," MINSA Document (2023).
7. G. F. Gonzales, C. Gonzales-Castañeda, "Desnutrición crónica infantil en el Perú: factores condicionantes y tendencias," *Revista Peruana de Medicina Experimental y Salud Pública* **39**, 1–11 (2022).
8. V. Tapia, B. Steenland, V. Saravia, G. F. Gonzales, "Mortalidad materna en el Perú: análisis de las inequidades regionales, 2010–2019," *Revista Peruana de Ginecología y Obstetricia* **67**, 123–132 (2021).
9. A. B. Lawson, *Bayesian Disease Mapping: Hierarchical Modeling in Spatial Epidemiology*, 3rd ed. (CRC Press, 2021).
10. M. Blangiardo and M. Cameletti, *Spatial and Spatio-temporal Bayesian Models with R-INLA* (Wiley, 2020).
11. A. Gelman, J. B. Carlin, H. S. Stern, D. B. Dunson, A. Vehtari, and D. B. Rubin, *Bayesian Data Analysis*, 3rd ed. (CRC Press, 2020).
12. R. McElreath, *Statistical Rethinking: A Bayesian Course with Examples in R and Stan*, 2nd ed. (CRC Press, 2020).
13. H. Rue, A. Riebler, S. H. Sørbye, J. B. Illian, D. P. Simpson, and F. K. Lindgren, "Bayesian computing with INLA: a review," *Annual Review of Statistics and Its Application* **9**, 395–421 (2022).
14. P. Moraga, *Geospatial Health Data: Modeling and Visualization with R-INLA and Shiny* (CRC Press, 2019).

- 533 15. A. Riebler, S. H. Sørbye, D. Simpson, and H. Rue, "An intuitive Bayesian
534 spatial model for disease mapping that accounts for scaling," *Statistical
535 Methods in Medical Research* **30**, 1100–1124 (2021).
- 536 16. A. R. Hosseinpoor, N. Bergen, S. Mendis, E. Harper, E. Verdes, A.
537 Kunst, and J. Y. Chatterji, "A global assessment of urban-rural inequalities
538 in access to essential health services," *The Lancet Global Health*
539 **10**, e234–e244 (2022).
- 540 17. M. E. Kruck, A. D. Gage, C. Arsenault, K. Jordan, H. H. Leslie, S. Roder-
541 DeWan, O. Adeyi, P. Barker, B. Daelmans, S. V. Doubova, M. English,
542 E. Elorrio, F. Guanais, J. Gureje, L. R. Hirschhorn, L. Jiang, E. Kelley,
543 E. Lemango, J. Liljestrand, A. Malata, T. Marchant, M. Matsoso, J.
544 E. Meara, M. Mohanan, Y. Ndiaye, O. F. Norheim, K. S. Reddy, A. K.
545 Rowe, J. A. Salomon, G. Thapa, N. A. Twum-Danso, and M. Pate,
546 "High-quality health systems in the Sustainable Development Goals
547 era: time for a revolution," *The Lancet Global Health* **9**, e1196–e1252
(2021).
- 548 18. M. A. Munga and N. G. Maestad, "Measuring inequalities in the distri-
549 bution of health workers: the case of Tanzania," *Human Resources for
550 Health* **18**, 1–12 (2020).
- 552 19. V. Vargas, M. Poblete-Cazenave, and S. Campos, "Barriers to health-
553 care access in rural Latin America: a systematic review," *International
554 Journal for Equity in Health* **20**, 234 (2021).
- 555 20. I. Bonfrer, E. van de Poel, and E. Van Doorslaer, "The effects of
556 performance incentives on the utilization and quality of maternal and
557 child care in Burundi," *Social Science & Medicine* **246**, 112727 (2020).
- 558 21. R. Strasser, J. Hogenbirk, I. Minore, M. Marsh, R. Berry, J. McCready,
559 and L. Graves, "Transforming health professional education through
560 social accountability: Canada's Northern Ontario School of Medicine,"
561 *Medical Teacher* **43**, 1–10 (2021).
- 562 22. M. C. Arcaya, A. L. Arcaya, and S. V. Subramanian, "Inequalities in
563 health: definitions, concepts, and theories," *Global Health Action* **13**,
564 1745986 (2020).
- 565 23. P. Braveman, S. Egarter, and D. R. Williams, "The social determinants
566 of health: coming of age," *Annual Review of Public Health* **44**, 25–42
567 (2023).
- 568 24. M. Lagarde and D. Blaauw, "A review of the application and contribu-
569 tion of discrete choice experiments to inform human resources policy
570 interventions," *Human Resources for Health* **18**, 1–11 (2020).
- 571 25. P. O. Ouma, J. Maina, P. N. Thurairira, T. Macharia, V. Alegana, M.
572 English, E. A. Okiro, and R. W. Snow, "Access to emergency hospital
573 care provided by the public sector in sub-Saharan Africa in 2015: a
574 geocoded inventory and spatial analysis," *The Lancet Global Health* **9**,
575 e342–e350 (2021).
- 576 26. J. F. Levesque, M. F. Harris, and G. Russell, "Patient-centred access to
577 health care: conceptualising access at the interface of health systems
578 and populations," *International Journal for Equity in Health* **19**, 1–9
(2020).